

Fundamentos de Arquitetura AI-First (PT-2)

Arquitetura de Sistemas com IA · Módulo 1.2

Prof. Ahirton Lopes, Ph.D.

Dos Pilares aos Componentes

01 Não-determinismo por design → Orquestrador com validação

O orquestrador confere a saída do modelo antes de seguir, não confia cegamente no primeiro output.

02 Approval Gates (HITL) → Approval Gate

Onde o risco é alto, a saída vira proposta que espera aprovação antes de virar ação.

03 Observabilidade (transversal) e auditoria → Trilha de eventos

Uma banda que atravessa todo o fluxo, cada etapa registrada com request-id e timestamp.


04 Custo e latência → Roteamento entre modelos

Modelo certo para cada tarefa, não o mais caro por padrão — aprofundado no Módulo 4.

05 Degradação graciosa → Fallback determinístico

Se o orquestrador não conseguir seguir, existe um caminho simples e prático de saída.

O Diagrama de Referência



Não Só Aqui: **Padrão de Indústria**

01 **AWS — Well-Architected Generative AI Lens**

Entrada, orquestração de agentes, modelo e observabilidade/governança — 8 cenários reais de arquitetura, do copiloto ao call center autônomo.

— AWS, Well-Architected Generative AI Lens (2025) + Agentic AI Lens (2026)

02 **Google Cloud — Architecture Center (RAG)**

Dois subsistemas: Ingestão (dados → embeddings → índice vetorial) e Serving (frontend → backend → Agent Platform) — nosso Modelo + Tools/RAG, em outra linguagem.


— Google Cloud, Architecture Center, Reference Architectures for RAG, 2025

03 **Microsoft Azure/Foundry — Baseline Chat Reference Architecture**

Foundry Agent Service, identidades gerenciadas, endpoints privados — o mesmo cuidado enterprise que colocamos na banda de Observabilidade.

— Microsoft, Azure Architecture Center, Baseline Microsoft Foundry Chat, 2026

TrialForge: a Requisição **Passo a Passo**



Um Diagrama. Quatro Componentes.

O diagrama de referência não muda de módulo para módulo — o que muda é o quanto cada componente precisa amadurecer.

Módulo 1.3 →

Framework de Decisão: Agente de IA ou Regras Determinísticas

O critério rápido de hoje vira um framework completo, com os casos-limite que ele não cobre.
