

Fundamentos de Arquitetura AI-First (PT-4)

Arquitetura de Sistemas com IA · Módulo 1.4

Prof. Ahirton Lopes, Ph.D.

Os Quatro Eixos do Orçamento

01 Latência

Tempo até a resposta. Cada chamada ao modelo soma rede + inferência; RAG e loops de agente multiplicam isso por etapa.

02 Custo

Preço por token de entrada e saída. Contexto grande (RAG com muitos documentos) e modelos maiores custam ordens de magnitude a mais.

03 Precisão

Quão perto do certo o modelo precisa chegar. Nem toda tarefa exige o modelo mais caro — algumas pedem exatamente isso.

04 Performance (Throughput)

Quantas requisições simultâneas o sistema aguenta sem degradar — rate limits do provedor, filas, capacidade de escalar.

Você Não Otimiza Tudo ao Mesmo Tempo

01 Ganhar latência custa em precisão ou custo

Modelo menor responde mais rápido, mas erra mais. Rodar vários modelos em paralelo pra escolher o melhor é rápido, mas caro.

02 Ganhar precisão custa em latência e custo

Modelo maior, mais contexto de RAG, mais etapas de verificação — cada camada de segurança adiciona tempo e preço.

03 Ganhar custo baixo costuma custar em latência ou precisão

Cache e modelos pequenos são baratos, mas só funcionam bem quando a tarefa tolera uma resposta menos afiada ou um pouco mais lenta em cache miss.

TrialForge: Orçamento por Componente

Componente	Latência	Custo	Precisão
Gateway	Baixa (crítica)	Baixo	N/A — é validação, não IA
Orquestrador	Baixa (crítica)	Baixo	Alta — decide o roteamento certo
Modelo + Tools/RAG	Tolerável (não é chat)	Alto se necessário	Alta — vira documento oficial
Approval Gate	Alta tolerância	N/A — é humano	N/A — é humano

Missão Prática #01

01 **Desenhe o Diagrama de Referência do seu caso**

Use o canvas do Módulo 1.2 e preencha os quatro componentes e a banda de observabilidade com um caso do seu próprio contexto de trabalho.

02 **Classifique cada componente com o Framework de 3 Perguntas**

Use o checklist do Módulo 1.3 pra decidir, componente por componente, agente ou regra — inclua ao menos uma tarefa híbrida.

03 **Atribua o orçamento de trade-off por componente**

Pra cada caixa, defina qual eixo é inegociável: latência, custo ou precisão — e qual você está disposto a sacrificar.

Entrega: diagrama preenchido + tabela de classificação + orçamento por componente + frase de reflexão final, num único arquivo.

Fundamentos Fechados. **Vamos Construir.**

Você sabe por que arquitetura AI-first é diferente, sabe desenhar o diagrama de referência, decidir onde cada tarefa mora nele, e orçar o custo de cada decisão.

Módulo 2 →

Arquiteturas Single-Agent

Abrimos a caixa Modelo + Tools/RAG do diagrama de referência: a anatomia interna de um agente único.
