

Módulo 4

Padrões de Design AI-Específicos

Arquitetura de Sistemas com IA

Prof. Ahirton Lopes, Ph.D.

Padrões de Design

AI-Específicos (PT-1)

Arquitetura de Sistemas com IA · Módulo 4.1

Prof. Ahirton Lopes, Ph.D.

A Caixa Que Ficou Preta Demais

01

Desde o Módulo 2, RAG já aparecia

O agente ICF já buscava cláusulas regulatórias — mas tratamos isso como caixa preta: 'busca e pronto'.

02

A ementa pede quatro padrões

Basic RAG, Hybrid Search, Multi-Index e Agentic RAG — cada um resolve uma limitação diferente da busca ingênua.

03

O motivo de abrir a caixa agora

TrialForge cresceu: três agentes, três tipos de documento, buscas que falham quando o termo exato não bate. É hora de arquitetura, não só conceito.

Basic RAG: A Anatomia Padrão




Hybrid Search: Quando Vetor Não Basta



Cormack, Clarke & Büttcher, “Reciprocal Rank Fusion outperforms Condorcet and Individual Rank Learning Methods”, SIGIR 2009
Lucidworks/Forrester: estudo de organização composta (design, manufatura e varejo) — 391% de ROI em 3 anos combinando busca exata e semântica.

Multi-Index: Uma Base Por Domínio



Roteamento por intenção — decidir EM QUAL índice buscar é o assunto inteiro do Módulo 4.2.

Agentic RAG: A Busca Vira Decisão



FLARE (Jiang et al., 2023) e Self-RAG (Asai et al., ICLR 2024) formalizaram a busca iterativa e autoavaliada antes do termo popularizar.

Consolidado como padrão em Singh et al., "Agentic Retrieval-Augmented Generation: A Survey on Agentic RAG", arXiv 2501.09136 (2025)

Fisher & Paykel + Salesforce Agentforce: atendimento 50% mais rápido, autoatendimento projetado para mais que dobrar, superando 65%.

TrialForge: Os 4 Padrões, Um Sistema

01

Basic RAG no Agente ICF

Já existia desde o Módulo 2 — busca simples de cláusula regulatória, um índice, uma volta.

02

Hybrid Search na busca de cláusula

O 'tema' que o modelo formula em linguagem natural passa a bater com a cláusula certa, mesmo sem repetir a frase exata do banco.

03

Multi-Index nos três agentes

Índice de cláusulas de consentimento, índice de critérios regulatórios, índice de estudos anteriores — cada agente busca no seu.

04

Agentic RAG na seção condicional

Decidir SE a seção de assentimento entra no documento pode exigir mais de uma busca — a mesma lógica do loop ReAct, agora dentro da busca.

Quatro Buscas Boas. Qual Modelo Responde?

RAG resolve o que o modelo sabe. Mas continua faltando decidir QUAL modelo processa essa busca — o mais caro e capaz para tudo, ou um roteamento inteligente que escolhe o modelo certo pra cada tarefa. É o assunto do próximo vídeo: Model Router e Intent-Based Routing.

Módulo 4.2 → Model Router e Intent-Based Routing: como decidir qual modelo processa cada busca.
