


Padrões de Design

AI-Específicos (PT-2)

Arquitetura de Sistemas com IA · Módulo 4.2


Prof. Ahirton Lopes, Ph.D.

Model Router: Nem Toda Tarefa Pesa Igual




RouteLLM (Berkeley/Anyscale/Canva, ICLR 2025): 95% da performance do GPT-4 usando esse modelo em só 26% das chamadas.
GPT-5 (OpenAI, ago/2025): sistema gpt-5-main + gpt-5-thinking com roteador retreinado continuamente com uso real — mas o lançamento também mostrou o risco: usuários reclamaram de respostas mais rasas, forçando ajuste público no roteamento.

Intent-Based Routing: **A Intenção Primeiro**



Zendesk Intelligent Triage: classificação automática de intenção antes do roteamento, mais confiável do que depender só de regra fixa de palavra-chave.

TrialForge: Roteamento Aplicado



Os dois padrões em sequência, não em paralelo: Intent-Based Routing decide O QUÊ fazer e ONDE buscar. Só depois, Model Router decide QUAL modelo processa.

Roteado e Barato. E a Pergunta Repetida?

Roteamento decide QUAL modelo responde. Mas se a mesma pergunta, ou uma pergunta parecida, já foi respondida antes, processar tudo de novo do zero é desperdício puro. É o assunto do próximo vídeo: cache semântico, cache de prompt, e response streaming.

Módulo 4.3 → Cache Semântico e Response Streaming: reaproveitar resposta parecida, entregar token a token.
