


Padrões de Design

AI-Específicos (PT-3)

Arquitetura de Sistemas com IA · Módulo 4.3

Prof. Ahirton Lopes, Ph.D.

Semantic Cache: A Pergunta Repetida



GPTCache (Fu Bang/Zilliz, NLP-OSS 2023): ganho de 2-10x na velocidade quando o cache acerta. Walmart: ~50% de acerto em consultas de cauda longa.

AWS ElastiCache (2025), benchmark com 63.796 perguntas reais: no limiar ótimo de 0,75, taxa de acerto de 90,3%, precisão de 91,2%, até 86% de redução de custo e 88% de latência — limiar frouxo demais (0,50) derruba a precisão pra 87,5%, apertado demais (0,99) derruba o acerto pra 23,5%.

Prompt Cache: O Contexto Que Não Muda

Um problema diferente do anterior

01 Semantic Cache pega pergunta repetida e pula a chamada inteira. Prompt Cache é outra coisa: o mesmo documento longo, ou o mesmo system prompt, é reenviado a cada nova pergunta DIFERENTE sobre esse contexto — e reprocessar esse contexto do zero, toda vez, é o desperdício aqui.

Dois provedores, já em produção

02 A Anthropic lançou prompt caching em agosto de 2024: até 90% de redução de custo e 85% de redução de latência em prompts longos. A OpenAI lançou caching automático em outubro de 2024, sem mudança de código, a partir de 1024 tokens, com 50% de desconto nos tokens cacheados.

Reuso modular vai além do prefixo exato

03 O paper Prompt Cache, de pesquisadores de Yale em colaboração com o Google, apresentado no MLSys 2024, reutiliza estados de atenção por SEGMENTO do prompt, não só quando o prefixo inteiro é idêntico — reduzindo o tempo até o primeiro token em 8 a 60 vezes.

Response Streaming: **Velocidade Sentida**

01 **O problema aqui não é velocidade real**
Cache reduz custo e latência de verdade. Streaming não reduz nada disso — o tempo total até a resposta completa continua o mesmo. O que muda é o que o usuário sente enquanto espera.

02 **Limiares que a interação humano-computador já conhece**
Jakob Nielsen documentou, ainda em 1993: até 0,1 segundo parece instantâneo; até 1 segundo o usuário nota o atraso mas continua no fluxo; a partir de 10 segundos a atenção se perde. São os mesmos limiares que se aplicam direto ao tempo até o primeiro token de uma resposta de IA.

03 **A prática documentada por quem constrói produto de IA**
A própria documentação oficial da OpenAI afirma: streaming é “a abordagem mais eficaz” pra reduzir a latência percebida, cortando a espera pra um segundo ou menos — “o ChatGPT pareceria bem diferente se você não visse nada até a resposta terminar.”

TrialForge: Cache e Streaming Juntos

Semantic Cache nas perguntas de rotina

- 01** CRAs e monitores de múltiplos sites fazem, de formas diferentes, as mesmas perguntas sobre o mesmo protocolo. Boa parte disso é candidata a Semantic Cache — com um cuidado: síntese do CSR nunca usa resposta de cache, é erro caro e irreversível (Módulo 1.3) demais pra arriscar uma resposta levemente desatualizada.

Prompt Cache no documento do protocolo

- 02** O protocolo de um estudo é longo e é reenviado como contexto em toda pergunta nova sobre ele, pelos três agentes. Prompt Cache evita reprocessar esse documento inteiro a cada pergunta — é o maior ganho de custo do TrialForge nesse módulo.

Response Streaming na síntese do CSR

- 03** A geração do CSR é a tarefa mais demorada do sistema. É exatamente onde streaming importa mais: o usuário vê o documento se formando token a token, em vez de olhar pra tela em branco por 10, 20 segundos.

Rápido e Barato. E Se Ninguém Aprovar?

Cache decide o que reaproveitar. Streaming decide como entregar. Mas nenhum dos dois decide se a resposta deveria sair sem revisão nenhuma. É o assunto do próximo vídeo: portões de aprovação, limiares de confiança, e trilha de auditoria — o Approval Gate do diagrama, formalizado.

Módulo 4.4 → Approval Gate formalizado: limiares de confiança e trilha de auditoria antes de qualquer resposta virar oficial.
