

Padrões de Design

AI-Específicos (PT-4)

Arquitetura de Sistemas com IA · Módulo 4.4

Prof. Ahirton Lopes, Ph.D.

Approval Gates: Pausar Antes de Agir



FDA, guidance de janeiro de 2025 sobre uso de IA em decisões regulatórias de medicamentos: framework de risco em 7 passos — aprovação humana reduz o nível de risco atribuído ao sistema.

Confidence Thresholds: Quando Escalar

01

Nem toda decisão pesa igual — o modelo já sabe disso

Todo modelo generativo carrega, internamente, algum sinal de quão certo ele está da própria resposta. Um limiar de confiança é a régua que decide: acima disso, segue sozinho; abaixo disso, para e escala.

02

A formalização acadêmica: aprender a adiar

Madras, Pitassi e Zemel, em “Predict Responsibly: Improving Fairness and Accuracy by Learning to Defer”, NeurIPS 2018, propõem um modelo que pode responder “passo” — adiando a decisão pra um humano — modelando explicitamente que esse humano também pode errar ou ter viés.

03

Três faixas, um caso real: Stripe Radar

O Stripe Radar atribui a cada pagamento uma pontuação de risco de 0 a 99. Acima de 65, o pagamento vai pra uma fila de revisão manual. Acima de 75, é classificado como alto risco. Nesse mesmo patamar de alto risco, o pagamento já é bloqueado automaticamente por padrão — três faixas, não duas: seguir sozinho, escalar, ou barrar.

Audit Trails: A Trilha Que Não Se Apaga

01

Sem trilha, aprovação não prova nada

Um portão de aprovação sem registro permanente de quem aprovou, o quê, e quando, não sobrevive a uma auditoria — é só teatro. A trilha é o que transforma “alguém aprovou” em fato verificável.

02

A exigência que já existe há décadas neste domínio

A norma 21 CFR Part 11 da FDA exige “trilhas de auditoria seguras, geradas por computador, com timestamp, que registram de forma independente a data e hora de entradas e ações do operador que criam, modificam ou excluem registros eletrônicos” — e essa trilha não pode ser sobrescrita, só adicionada.

03

A mesma exigência, fora do universo farmacêutico

O Artigo 12 do EU AI Act exige que sistemas de IA de alto risco permitam tecnicamente o registro automático de eventos ao longo de toda a vida do sistema — o mesmo princípio do 21 CFR Part 11, agora como regulação geral de IA, não só de medicamento.

TrialForge: **Approval Gate** Formalizado

Approval Gate na síntese do CSR

- 01** A síntese final do CSR — erro caro e irreversível, framework do Módulo 1.3 — sempre passa por um portão de aprovação antes de virar documento oficial: o fluxo pausa, exatamente como o `interrupt()` do LangGraph, e só prossegue quando o especialista regulatório aprova.

Confidence Thresholds no Agente ICF

- 02** Extrações e gerações de alta confiança seguem direto. Abaixo de um limiar calibrado, o Agente ICF escala pro Approval Gate — a mesma lógica de três faixas do Stripe Radar, aplicada a seções de documento em vez de pagamentos.

Audit Trail atravessando os três agentes

- 03** Toda aprovação, toda decisão de limiar, toda versão de prompt e de modelo fica registrada numa trilha que só cresce, nunca é sobrescrita — é a banda de Observabilidade do diagrama do Módulo 1.2, agora com a exigência regulatória exata (21 CFR Part 11) por trás dela.

Quatro Padrões. Hora de Construir.

RAG, roteamento, cache e streaming, e agora o Approval Gate formalizado — os quatro grupos de padrão do Módulo 4 já foram vistos, um de cada vez. No próximo vídeo, os quatro juntos, rodando de verdade num protótipo só, e a Missão Prática número 4.

Módulo 4.5 → O protótipo completo: os quatro padrões rodando juntos num Gateway só, mais a Missão Prática #04.
