

Módulo 5

Arquitetura Enterprise

Arquitetura de Sistemas com IA

Prof. Ahirton Lopes, Ph.D.

Arquitetura

Enterprise (PT-1)

Arquitetura de Sistemas com IA · Módulo 5.1

Prof. Ahirton Lopes, Ph.D.

De Um Estudo, **Pra Dezenas**

01

Tudo que construímos até aqui resolve UMA requisição

Gateway, Orquestrador, Modelo+RAG, Approval Gate — o diagrama do Módulo 1.2 decide bem uma submissão de cada vez, de um estudo só.

02

A Vitalis Pharma não roda um estudo


Roda dezenas, ao mesmo tempo, em múltiplos países, com equipes regulatórias diferentes — cada uma gerando volume próprio de requisições pro mesmo sistema.

03

Multiplicar não é só rodar mais rápido


É decidir quem compartilha o quê: mesmo Gateway pra todos os estudos? Mesmo modelo? Mesma trilha de auditoria, ou uma por estudo? Essas decisões têm nome, e são o assunto do Módulo 5.

O Stack Completo: Da Requisição à Plataforma



Ex.: LiteLLM (uso interno na Netflix, 100+ provedores), Cloudflare AI Gateway, Kong AI Gateway.

Kubernetes: Escalar Sem Recriar



KServe (CNCF, Incubating desde set/2025): campo `canaryTrafficPercent` divide tráfego entre versão estável e nova, com rollback só voltando o percentual pra 0.

Kubeflow (Google, CNCF, anunciado dez/2017): projeto irmão que orquestra o pipeline de treino, não o serviço em produção — camada diferente, não concorrente do KServe.

Eval Gate: Promover Não é Só Rodar Sem Erro

O canary avisa depois — o eval gate decide antes

- 01** O canary do KServe (slide anterior) resolve COMO trocar de versão sem desligar o sistema — mas não resolve SE a versão nova deveria virar produção. Um candidato ruim ainda entra, só que devagar; o problema aparece na métrica de produção, não antes dela.

Golden set: perguntas com resposta esperada, testadas antes de promover

- 02** O candidato roda contra um conjunto fixo de perguntas com cláusula esperada conhecida — o mesmo mecanismo de groundedness $g(\text{pergunta}, \text{resposta})$ do Módulo 5.4. Só promove se o score médio não regredir além de uma tolerância contra o baseline atual.

Testado de verdade: dois modelos reais, dois resultados diferentes

- 03** gemma4:e2b (baseline) contra gemma4:e2b-mlx (candidato real, mesma família): caso limite, dentro da tolerância — promove. O mesmo baseline sem a cláusula no contexto (bug real de config, não modelo pior): score despenca, e o gate bloqueia — pegou uma regressão que nenhuma troca de modelo causou.

Três Princípios: **Arquitetura Enterprise**

01

Loose Coupling — acoplamento fraco (modularidade)

Um estudo pode trocar de versão de modelo, ou de índice de busca, sem quebrar os outros 29. Raiz em Stevens, Myers & Constantine, 'Structured Design', IBM Systems Journal, 1974.

02

Clear Interfaces — contratos explícitos (modularidade)

Cada serviço compartilhado expõe um contrato fixo, não implementação. Formalizado por Sam Newman em 'Building Microservices' e por Thomas Erl em 'SOA: Principles of Service Design' (2008).

03

Policy-Driven Control — política como código (segurança)

Quem pode chamar qual modelo, com qual limite de custo, não fica decidido no código de cada agente — fica numa política central, avaliada em tempo de execução (Open Policy Agent, CNCF, graduado em 2021).

Vitalis Platform: **TrialForge** Multiplicado

01

Um Gateway, todos os estudos

A Uber documentou exatamente esse problema: o GenAI Gateway do time Michelangelo atende 60+ casos de uso e cerca de 30 times internos, com 16 milhões de consultas por mês, pela mesma porta de entrada.

02

Serviços compartilhados, não reimplementados por estudo

Redação de PII, autenticação, e integração com cada provedor de modelo existem uma vez só na plataforma da Uber — não uma cópia por time. A Vitalis Platform aplica o mesmo princípio: um serviço de embedding, um serviço de modelo, compartilhados por ICF, Protocolo e CSR de cada estudo.

03

Portão de revisão antes de qualquer time novo entrar

Na Uber, um time de segurança aprova cada caso de uso antes dele ganhar acesso ao Gateway. Na Vitalis Platform, cada novo estudo passa por uma revisão equivalente antes de herdar a infraestrutura compartilhada — o Approval Gate do Módulo 1.2, agora aplicado à própria plataforma, não só ao documento.

A Plataforma Existe. Mas Alguém Está Vendo?

Um Gateway compartilhado por 30 estudos falha de um jeito que um Gateway de um estudo só nunca falharia: o problema de um estudo se esconde no ruído dos outros 29. O próximo vídeo é sobre isso — observabilidade quando a escala deixa de ser desculpa e vira o próprio risco.

Módulo 5.2 → Observabilidade em Escala: os sinais que capturam quando o sistema quebra, não só quando fica ocupado.
