

Arquitetura

Enterprise (PT-3)

Arquitetura de Sistemas com IA · Módulo 5.3

Prof. Ahirton Lopes, Ph.D.

Serverless: O Problema do Cold Start



Google Cloud documenta essas 4 fases pra IA no Cloud Run. Mitigação mais citada: quantização de 4 bits — menos peso pra mover é menos tempo de cold start.

Modal: boot de até 2000s caiu pra ~50s com snapshot de memória de GPU (40x mais rápido). AWS Bedrock (serverless): “você não precisa gerenciar infraestrutura nenhuma”, cobrando por token.

Edge: Mais Perto, Mais Privado

01 **Cloudflare Workers AI**
GPUs em mais de 180 cidades ao redor do mundo — 95% da população conectada à internet fica a menos de 50ms de distância de um data center Cloudflare.

02 **Apple Intelligence**
Modelo de ~3 bilhões de parâmetros rodando direto no dispositivo, com quantização de 2 bits. Requisição maior cai pro Private Cloud Compute, que a Apple declara nunca guardar nem compartilhar dado — nem com a própria Apple.

03 **Google Gemini Nano, no Android**
Roda dentro do serviço AICore do próprio sistema: “remove a latência de rede, velocidade de inferência depende só do hardware do dispositivo” — nas palavras da própria documentação — e funciona offline.

Kingfisher: **Decisão Por Componente**

Uma rede varejista real, decidindo por tráfego, não por preferência

01 A Kingfisher plc, dona de B&Q, Screwfix e Castorama, documentou publicamente: mais de 130 pipelines de treino e previsão de demanda rodam em Kubeflow, serverless, porque a necessidade de recurso é altamente elástica.

Mas a inferência ao vivo vai pra Kubernetes

02 A mesma equipe roda inferência em produção — a parte que responde ao cliente em tempo real — em Kubernetes via GKE, porque esse tráfego “é consistente, previsível, alto”. Mesmo time, dois modelos de implantação, uma decisão por componente.

Existe até um ponto de virada calculável

03 A própria Kingfisher mediu: computação serverless sai a cerca de \$82,77 por vCPU-mês contra \$39,73 num modelo convencional — cerca do dobro. A DigitalOcean documenta a regra prática: acima de 22-48% de utilização constante, hospedar a própria GPU sai mais barato que pagar por uso.

AWS, guia de arquitetura de sistemas de agentes: “uma vantagem arquitetural chave de rodar agentes em infraestrutura híbrida é decompor a carga de trabalho e posicionar cada componente no tipo de instância mais adequado.”

medRxiv (2025): 261 hospitais na China continental (93,5% das províncias) já tinham implantado o DeepSeek-R1 localmente até início de março de 2025 — 84% deles unidades terciárias, ainda cerca de 0,7% do total de hospitais do país.

Vitalis Platform: **Implantação Híbrida**

01

Gateway e Orquestrador — Kubernetes, sempre ligado

Tráfego constante, alto volume, todos os estudos batendo o dia inteiro — exatamente o perfil que a Kingfisher mantém em Kubernetes, não em serverless.

02

Agente CSR — serverless, sob demanda

Síntese de CSR é rara e não-previsível: um estudo gera um punhado de vezes, não o dia inteiro. Pagar por infraestrutura sempre ligada pra isso é exatamente o desperdício que a Kingfisher evita rodando batch elástico fora do Kubernetes.

03

Revisão do Approval Gate — nenhum dos dois, é interativo

Onde o especialista regulatório revisa e aprova, a prioridade é latência de resposta da interface, não custo por chamada de modelo — esse componente pede capacidade reservada mínima, não cold start, mesmo sendo um componente de baixo volume.

Cada Peça no Seu Lugar. Falta Decidir o Modelo.

Onde cada componente roda é uma decisão. Qual modelo processa cada chamada — do Módulo 4.2, Model Router — é outra, e as duas se somam no orçamento final. No último vídeo da disciplina, um protótipo com roteamento de modelo em cascata e controle de custo de verdade, rodando na sua máquina — e a Missão Prática que fecha a disciplina inteira.

Módulo 5.4 → O protótipo final: roteamento de modelo em cascata, controle de custo real, e a Missão Prática que fecha a disciplina.
